

سوال ۱. سوال تئوری ۱

اگر جامعه را بتوان به خوشه های مجزا از افرادی با سلیقه ی یکسان افراز کرد، به طوری که افراد یک خوشه با افراد خوشه ی دیگر هیچ اشتراکی نداشته باشند، آنگاه ماتریس مجاورت این افراد به چه صورت خواهد بود؟
اولا که ماتریس متقارن است زیرا که روابط دوطرفه هستند. ثانيا به علت اینکه همه ی افراد یک خوشه با هم در ارتباط هستند و یال دارند، میتوان ادعا کرد که یک جایگشت سطری ستونی از ماتریس مجاورت وجود دارد به گونه ای روی قطر آن چندین ماتریس مربعی کاملاً یک باشند و مابقی ماتریس صفر. مثل ماتریس جوردن ولی همه ی درایه های بلوک ها یک هستند و نه صفر.

سوال ۲. سوال تئوری ۲

اولا که ماتریس متقارن است زیرا که روابط دوطرفه هستند. ثانيا به علت اینکه همه ی افراد یک خوشه با هم در ارتباط هستند و یال دارند، میتوان ادعا کرد که یک جایگشت سطری ستونی از ماتریس مجاورت وجود دارد به گونه ای روی قطر آن چندین ماتریس مربعی کاملاً یک باشند و مابقی ماتریس صفر. مثل ماتریس جوردن ولی همه ی درایه های بلوک ها یک هستند و نه صفر.
در این حالت می توان سطر و ستون های ماتریس را به گونه ای جابجا کرد که هر بخش متعلق به یک خوشه باشد و هر فرد یا با تمام افراد خوشه در ارتباط هست و یا کلاً با آن در ارتباط نیست. پس شکل مثل زیر خواهد شد. (هر رنگ یک خوشه و سلیقه است و بخش های رنگی یک و غیر رنگی صفر است.

سوال ۳. سوال تئوری ۳

فرض کنید M ژانر مختلف فیلم داریم. اگر دو نفر به ژانر ۱، ۲، ...، i ام علاقه داشته باشند، به احتمال i با یکدیگر هم سلیقه اند، حال فرض کنید دو شخص خاص هر کدام به چند ژانر مختلف علاقه دارند. اگر فرض کنیم علاقه به π ژانرهای مختلف از هم مستقلند، احتمال اینکه این دو نفر با یکدیگر هم سلیقه باشند چقدر است؟
چرا اگر دو نفر در جوامع خاص زیادی عضو باشند احتمال اینکه با هم در ارتباط باشند بیشتر می شود؟ آیا می توانید این مسئله را به صورت شهودی هم توجیه کنید؟ به نظر شما این مدل چه نقصی در مدل کردن رابطه ی افراد و گروه ها دارد؟ شکل ۳ را در این خصوص ببینید.
احتمال هم سلیقه بودن با فرض علاقه به ژانرهای مجموعه ی A :

$$1 - \prod_{i \in A} (1 - p_i)$$

زیرا هر چه در جوامع بیشتری باشند، تعداد جملات پای در فرمول بالا بیشتر می شود و چون هر جمله کمتر از یک است، پس در نهایت احتمال هم سلیقه ی بیشتر می شود. تعداد ژانرها محدود است و هر چه تعداد بیشتری را دوست داشته باشید در ارتباط با افراد بیشتری که آن را دوست دارند قرار می گیرید و احتمال اینکه با فردی هم سلیقه شوید بیشتر خواهد بود. پس به طور شهودی نیز تطابق دارد. - نقص ها - تعلق به یک گروه صفر و یکی است و وزن ندارد در صورتی که وزنی بهتر توصیف می کند - حالات بین خوشه ای به طور بهینه مدل نشده اند، زیرا ممکن است

یک ترکیب از تعدادی خوشه خودش یک خوشه‌ی دارای اصالت باشد. - ممکن است خوشه‌ها بر اساس ژانر فیلم نباشند و معیارهای دیگری مثل کارگردان و بازیگران و کمپانی و ... نیز در خوشه‌ها باشند.

سوال ۴. سوال تئوری ۴

$$P_{uv} = 1 - \prod_{i=1}^c \exp(-F_{ui}F_{vi}) = 1 - \exp\left(-\sum_{i=1}^c (F_{ui}F_{vi})\right)$$

سوال ۵. سوال تئوری ۵

رابطه‌ها رو می‌نویسیم و بدست می‌آوریم:

$$\begin{aligned} P(A|F) &= \prod_{u,v=1}^n [A_{uv}P_{uv} + (1 - A_{uv})(1 - P_{uv})] \\ \Rightarrow l(F) &= \sum_{u,v=1}^n \log(A_{uv}P_{uv} + (1 - A_{uv})(1 - P_{uv})) \\ &= \sum_{u,v=1}^n \log(2A_{uv}P_{uv} + 1 - A_{uv} - P_{uv}) \\ &= \sum_{u,v=1}^n \log\left(2A_{uv}\left(1 - \exp\left(-\sum_{i=1}^c F_{ui}F_{vi}\right)\right) + A_{uv} + \exp\left(-\sum_{i=1}^c F_{ui}F_{vi}\right)\right) \\ &= \sum_{u,v=1}^n \log\left(2A_{uv} + (1 - 2A_{uv})\exp\left(-\sum_{i=1}^c F_{ui}F_{vi}\right)\right) \end{aligned}$$

سوال ۶. سوال تئوری ۶

این روش در اصل همان روش descend gradient است که کاربرد زیادی در محاسبات عددی دارد. در این روش از نقطه یا نقاطی روی نمودار شروع می‌کنیم و در هر گام مقدار اندکی در راستای گرادیان در آن نقطه جابجا می‌شویم و به نقطه‌ی جدید می‌رویم. اگر این کار را با تعداد گام و طول گام مناسب انجام بدهیم انتظار داریم که به نقطه‌ی اکسترمم موضعی برسیم. اما برای این کار شرایطی لازم است. اولاً اینکه تابع پیوسته باشد که تابع ما جمع چند لگاریتم پیوسته است پس پیوسته است. همچنین نوسانات شدید در تابع باعث می‌شوند که روش به خوبی کار نکند. در این تابع ما نوسانات شدید هم وجود ندارد. همچنین نکته‌ی دیگر اینست که این روش به ما اکسترمم موضعی را می‌دهد و گلوبال و به شرطی که فقط یک اکسترمم داشته باشیم قطعاً به اکسترمم گلوبال می‌رسیم. همچنین نواحی با گرادیان صفر نباید وجود داشته باشند تا الگوریتم متوقف نشود و یا در دور نیافتد.

سوال ۷. سوال تئوری ۷

$$\nabla F_{w,i} = \sum_{v=1}^n \frac{(1 - \alpha A_{wv}) (-\sum_{i=1}^C F_{vi}) \exp(-\sum_{i=1}^C F_{wi} F_{vi})}{\alpha A_{wv} + (1 - \alpha A_{wv}) \exp(-\sum_{i=1}^C F_{wi} F_{vi})}$$

سوال ۸. سوال شبیه سازی ۱

```
def log_likelihood(F, A):
    N = A.shape[0]
    C = F.shape[1]
    log_likelihood = 0
    for u in range(N):
        for v in range(N):
            summ=0
            for i in range(C):
                summ += F[u][i]*F[v][i]
            log_likelihood += numpy.log(3*A[u][v]+(1/2*A[u][v]))*
            numpy.exp( summ))
    return log_likelihood

def gradient(F, A, i):
    gradient = list()
    N = A.shape[0]
    C = F.shape[1]
    for w in range(N):
        element = 0
        for v in range(N):
            summ = 0
            summp = 0
            for i in range(C):
                summp += F[v][i]
                summ += F[v][i] * F[u][i]
            element += ((1/2*A[w][v])*(summp)*numpy.exp( summ))
        / (3*A[w][v] + (1/2*A[w][u]) * (numpy.exp( summ)))
        gradient.append(element)

    return gradient

def train(A, C, iterations = 200):
    # initialize an F
    N = A.shape[0]
    F = np.random.rand(N,C)
```

```

for n in range(iterations):
    for person in range(N):
        grad = gradient(F, A, person)
        F[person] += 0.005*grad # updating F
        F[person] = np.maximum(0.001 , F[person])
        # F should be nonnegative
ll = log_likelihood(F, A)
print('At step %4i logliklihood is %5.4f'%(n,ll))

return F

```

سوال ۹. سوال تئوری ۸
در کدها انجام شده!

سوال ۱۰. سوال تئوری ۹

$$A_{ij} = \begin{cases} p, z_i = z_j \\ q, z_i \neq z_j \end{cases}$$

سوال ۱۱. سوال تئوری ۱۰

خیر- درایه‌های روی قطر اصلی باید همگی یک باشند ولی برابر با p هستند. همچنین درایه‌های متقارن باید با هم برابر باشند در صورتی که در توصیف احتمالاتی بالا ممکن است متفاوت باشند.

$$A_{ij} = \begin{cases} 1, i = j \\ p, z_i = z_j, i < j \\ q, z_i = z_j, i < j \\ A_{ji}, i > j \end{cases}$$

سوال ۱۲. سوال شبیه‌سازی ۲

```

import numpy as np
import random
from scipy.stats import bernoulli
import networkx
# import networkx

```

```

n = 15
k = 3
p = 0.6
q = 0.1
Q = np.arange(k*k, dtype=float).reshape(k,k)
for i in range(k):
    for j in range(k):
        Q[i][j] = p if i==j else q

def create_uniform_z(n,k):
    poeple_at_table = [0 for i in range(k)]
    z = list()
    for i in range(n):
        v = random.randint(1,k)
        while(poeple_at_table[v-1]==n/k): v = random.randint(1, k)
        poeple_at_table[v-1] += 1
        z.append(v)
    return np.array(z)

def create_A():
    z = create_uniform_z(n, k)
    A = np.arange(n*n).reshape(n,n)
    for i in range(n):
        for j in range(n):
            value = int(bernoulli(Q[z[i]-1][z[j]-1]).rvs(1))
            if(i==j): value = 1
            elif(i>j): value = A[j][i]
            A[i][j] = value
    return A,z

for i in range(10):
    A,_ = create_A()
    print(A)

```

سوال ۱۳. سوال شبیه سازی ۳

```

import numpy as np
import random
from scipy.stats import bernoulli

```

```

import networkx
import networkx as nx

n = 15
k = 3
p = 0.6
q = 0.1
Q = np.arange(k*k, dtype=float).reshape(k,k)
for i in range(k):
    for j in range(k):
        Q[i][j] = p if i==j else q

def create_uniform_z(n,k):
    poeple_at_table = [0 for i in range(k)]
    z = list()
    for i in range(n):
        v = random.randint(1,k)
        while(poeple_at_table[v-1]==n/k): v = random.randint(1, k)
        poeple_at_table[v-1] += 1
        z.append(v)
    return np.array(z)

def create_A():
    z = create_uniform_z(n, k)
    A = np.arange(n*n).reshape(n,n)
    for i in range(n):
        for j in range(n):
            value = int(bernoulli(Q[z[i]-1][z[j]-1]).rvs(1))
            if(i==j): value = 1
            elif(i>j): value = A[j][i]
            A[i][j] = value
    return A,z

A,z = create_A()
G = nx.Graph()
for i in range(n):
    G.add_node(i, table=z[i])

for i in range(n):
    for j in range(n):
        if i == j:

```

```

        A[i][j] == 0
    if A[i][j] == 1:
        G.add_edge(i, j)
print("hello")
# nx.draw_networkx_labels(G, pos)
nx.draw(G)

```

سوال ۱۴. سوال شبیه سازی ۴

```

def hamming_distance(a:np.array,b:np.array):
    return int(np.linalg.norm(a - b,ord=0))
a= np.array([2,2,1,2,2,1])
b= np.array([1,1,2,1,2,2])
print(hamming_distance(a, b))

```

سوال ۱۵. سوال شبیه سازی ۵

```

def permutation(lst):
    if len(lst) == 0:
        return []

    if len(lst) == 1:
        return [lst]

    l = [] # empty list that will store current permutation

    for i in range(len(lst)):
        m = lst[i]

        remLst = lst[:i] + lst[i+1:]
        for p in permutation(remLst):
            l.append([m] + p)
    return l

def hamming_distance(a:np.array,b:np.array):
    return int(np.linalg.norm(a - b,ord=0))

def get_class_of_vector(a:np.array, n:int):
    nlist = list(range(1,n+1))

```

```

aClass = list()
for p in permutation(nlist):
    aCopy = a.copy()
    for i,v in enumerate(aCopy):
        aCopy[i] = p[v 1]
    aClass.append(aCopy)
return aClass

def min_hamming_distance(a:np.array, b:np.array, k:int):
    # k table counts
    aClass = get_class_of_vector(a, k)
    return min(list([ hamming_distance(x,b) for x in aClass]))

print(min_hamming_distance(a, b, 2))

```

سوال ۱۶. سوال تئوری ۱۱

$$\frac{N^* - N}{2}$$

سوال ۱۷. سوال تئوری ۱۲

$$L(z) = \prod_{i,j=1, i < j}^n A_{ij}$$

سوال ۱۸. سوال تئوری ۱۳

$$\sum_{i,j=1, i < j}^n \log(A_{ij})$$

سوال ۱۹. سوال شبیه سازی ۶

```

def Liklyhood(A,z):
    p = 0
    for i in range(n):
        for j in range(n):
            # print(z[i], z[j])
            p += np.log(Q[z[i] 1][z[j] 1]) if A[i][j]==1

```



```

        else (1 - Q[z[i] - 1][z[j] - 1]))
    return p

```

```

A, z = create_A()
Liklyhood(A, z)

```

سوال ۲۰. سوال شبیه سازی ۷

```

def get_z0(n, k):
    result = list()
    for i in range(int(k)):
        for j in range(int(n/k)):
            result.append(i+1)
    # print("z0 is:", result)
    return np.array(result)

# Q7
def z_fit(A, realz, z0=get_z0(n, k),):
    dlist = list()
    # z0 = get_z0(n, k)
    if len(z0) != n:
        # print("FAAALSE!")
        pass
    T = 5
    bestL = 1e9
    for t in range(T):
        initial_L = Liklyhood(A, z0)
        bestL = initial_L
        MaxDelta = 0
        best = (0, 0)
        for i in range(n):
            for j in range(n):
                temp = z0[i]
                z0[i] = z0[j]
                z0[j] = temp
            delta = initial_L - Liklyhood(A, z0)
            if delta > MaxDelta:
                MaxDelta = delta
                best = (i, j)
            bestL = initial_L - delta
        temp = z0[i]

```

```

        z0[i] = z0[j]
        z0[j] = temp
    if best[0]==0:
        print("not completed")
        break
    temp = z0[best[0]]
    z0[best[0]] = z0[best[1]]
    z0[best[1]] = temp
    dlist.append(min_hamming_distance(z0, realz, k))
return bestL, z0, dlist

```

```

A, z0 = create_A()
bestL, z, dlist = z_fit(A, z0)
dlist

```

سوال ۲۱. سوال شبیه سازی ۸

```

A,z = create_A()
reall = Liklyhood(A,z)
ZList = list()
LList = list()
print("best L:", reall)
for i in range(10):
    startZ = create_uniform_z(n,k)
    L,z0,_ = z_fit(A, z, startZ)
    ZList.append(z0)
    LList.append(L)
    print("L=",L, "\tZ=",z0)

```

سوال ۲۲. سوال شبیه سازی ۹

```

for LItem, ZItem in zip(LList, ZList):
    if LItem == reall:
        print("found a perfect Z", ZItem)
        print("min hamming distance is",
              min_hamming_distance(ZItem, z, k))

```

سوال ۲۳. سوال شبیه سازی ۱۰

کد این سوال همان کد بالا است در واقع. همان طور که در بالا یافتیم تعدادی هستند که فاصله شان صفر شده است.

سوال ۲۴. سوال شبیه سازی ۱۱

کد این سوال نیز همان کد سوال ۲۲ می باشد. برای این کار کد بخش بالا را دوبار دیگر اجرا می کنیم.

سوال ۲۵. سوال تئوری ۱۴

درایه های ماتریس $A_{i,j}$ نشان می دهند که بین دوتا راس i و j یالی وجود دارد یا خیر وقتی یالی باشد یک نشان می دهد و اگر نه، ۰ نشان می دهد. PMF حاصل:

$$P_X(x) = \begin{cases} \frac{p+q}{2}, & x = 1 \\ 1 - \frac{p+q}{2} & x = 0 \end{cases}$$

همچنین

$$A_{i,j} \sim \text{Bern}\left(\frac{p+q}{2}\right)$$

سوال ۲۶. سوال تئوری ۱۵

در متغیر برنولی، exp با احتمال برابر است بنابراین خواهیم داشت:

$$E[A_i, i] = \frac{p+q}{2}$$

سوال ۲۷. سوال تئوری ۱۶

ماتریس A مربوط به این سوال به شکل زیر خواهد بود

$$\begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{bmatrix}$$

همچنین ماتریس W به شکل زیر خواهد بود:

$$\begin{bmatrix} p & p & q & q \\ p & p & q & q \\ q & q & p & p \\ q & q & p & p \end{bmatrix}$$

$$|W - I\lambda| = 0$$

برای محاسبه‌ی مقدار ویژه، باید از ماتریس داده شده، لاندا برابر از ماتریس همانی را کم کرده، از ماتریس حاصل دترمینان بگیریم و آنرا مساوی صفر قرار دهیم. با حل کردن معادله، مقادیر مختلف لاندا بدست می‌آید که مقادیر ویژه‌ی ما هستند بنابراین داریم:

$$\begin{bmatrix} p - \lambda & p & q & q \\ p & p - \lambda & q & q \\ q & q & p - \lambda & p \\ q & q & p & p - \lambda \end{bmatrix}$$

میدانیم در محاسبه‌ی ماتریس، برای سهولت کار میتوانیم ضربی از یکی از سطرها را از سطری دیگر کم کنیم. پس با استناد به این، دترمینان ماتریس بالا با این ماتریس برابر خواهد بود:

$$\begin{bmatrix} -\lambda & \lambda & 0 & 0 \\ p & p - \lambda & q & q \\ q & q & p - \lambda & p \\ 0 & 0 & \lambda & -\lambda \end{bmatrix}$$

دترمینان حاصل خواهد بود:

$$\lambda^2(\lambda^2 - 4p\lambda + 4(p^2 - q^2))$$

با برابر صفر قرار دادن عبارت بالا، جواب‌های ممکن برای لاندا بدین شکل خواهند بود:

$$(0, 0, 2p + 2q, 2p - 2q)$$

با داشتن لانداها، بردار ویژه‌ها را محاسبه خواهیم کرد:

$$\frac{1}{\sqrt{4}} \begin{bmatrix} 1 \\ -1 \\ 1 \\ -1 \end{bmatrix}$$

سوال ۲۸. سوال تئوری ۱۷

از آنجایی که در کل دو خوشه سلاقی داریم و هرکس در یکی از این دو است، به این نتیجه می‌رسیم که افراد هم خوشه، ستون‌ها و سطرهای یکسانی در ماتریس مجاورت خواهند داشت. پس کل ستون‌ها به دو نوع تقسیم می‌شوند. به همین دلیل تعداد ستون‌های مستقل خطی دوتا است و می‌دانیم تعداد مقادیر ویژه غیر صفر برابر با رنک ماتریس است در نتیجه دو مقدار ویژه غیر صفر داریم. می‌دانیم هر ماتریس متقارن، n بردار ویژه عمود به هم دارد. پس با جای‌گذاری مقادیر ویژه در معادله اولیه n ، بردار ویژه بدست خواهد آمد.

می‌دانیم ماتریس W به شکل ماتریس یک گراف منتظم است و برای این ماتریس‌ها، بردار $\mathbf{1}$ ، یک بردار ویژه است، پس داریم: (فرض کنیم m تا راس از یک دسته و باقی از دسته دیگر باشند.)

$$W\mathbf{1} = \lambda\mathbf{1} \rightarrow mp + (n - m)q = \lambda$$

$$\text{trace}(W) = \lambda_1 + \lambda_2 = np$$

$$\rightarrow \lambda_1 = mp + (n - m)q, \lambda_2 = (n - m)p + (m - n)q$$

جمع درایه‌های روی قطر ماتریس برابر با جمع مقادیر ویژه آن است. بردارهای ویژه نیز با جای‌گذاری مقادیر ویژه بدست می‌آیند.

سوال ۲۹. سوال تئوری ۱۸

در واقع باید سطرهای W را جمع بزنیم و در درایه قطری مورد نظر قرار دهیم. اگر m نفر از دسته یک و $n - m$ نفر از دسته دو باشند، برای هر راس از جمله خودش به همین تعداد p و q داریم. تمام درایه‌های قطری برابر با $mp + (n - m)q$ است $\mathbf{2} = m$ بود.

$$\text{در حالت } m = n/2:$$

$$\begin{bmatrix} \frac{n(p+q)}{2} & 0 & \dots & 0 \\ 0 & \frac{n(p+q)}{2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{n(p+q)}{2} \end{bmatrix}$$

سوال ۳۰. سوال تئوری ۱۹

$$L_W = \begin{bmatrix} (\frac{n}{4} - 1)p + \frac{nq}{4} & -p & . & . & -q \\ -p & (\frac{n}{4} - 1)p + \frac{nq}{4} & . & . & . \\ . & . & . & . & . \\ . & . & . & . & . \\ -q & -q & . & . & (\frac{n}{4} - 1)p + \frac{nq}{4} \end{bmatrix}$$

$$L_W v = \lambda v \rightarrow W v = D_W v - \lambda v = (\frac{n}{4}(p+q) - \lambda)v \rightarrow \text{eigenvalues of } W = \begin{cases} . \rightarrow \lambda = \frac{n}{4}(p+q) \\ \frac{n}{4}(p+q) \rightarrow \lambda = . \\ \frac{n}{4}(p-q) \rightarrow \lambda = nq \end{cases}$$

سوال ۳۱. سوال تئوری ۲۰

با توجه به بردار ویژه‌های محاسبه شده برای L_w نقاط جدید به صورت زیر تبدیل می‌شوند:

$$\lambda_1 = . \rightarrow v_1 = (1, 1, 1, 1)^T$$

$$\lambda_2 = 4q \rightarrow v_2 = (1, 1, -1, -1)^T$$

$$1 : (1, 1)$$

$$2 : (1, 1)$$

$$3 : (1, -1)$$

$$4 : (1, -1)$$

پس خوشه‌ها به خوبی از هم جدا می‌شوند وقتی نمودار را بکشیم.

سوال ۳۲. سوال شبیه‌سازی ۱۲

```
import numpy as np
import random
n = 1000
p = 0.1
q = 0.01
```

```

A = np.zeros((n,n))
W = np.zeros((n,n))
jamee = np.array([0]* (n))
for i in jamee:
    i = random.randint(0,1)

for i in range(n):
    for j in range(i+1, n):
        if jamee[i] == jamee[j] and random.random() < p:
            A[i,j] = 1
            A[i, j] = 1
        elif jamee[i] != jamee[j] and random.random() < q:
            A[i,j] =1
            A[i, j] = 1
D_A = np.diag(np.sum(A, axis = 1))
L_A = D_A - A
eigenValues, eigenVectors = np.linalg.eig(L_A)
n = eigenValues.copy()
n.sort()
a = b =0
for i in range(len(eigenValues)):
    if eigenValues[i] == n[0]:
        a = i
        break
for i in range(len(eigenValues)):
    if eigenValues[i] == n[1] and i != a:
        b = i
print(eigenVectors[a], eigenVectors[b])

```

سوال ۳۳. سوال تئوری ۲۱

برای دستیابی به احتمال بالای $1 - \epsilon$ داریم:

$$\begin{aligned}
 1 - 4e^{-n} &> 1 - \epsilon \rightarrow 4e^{-n} < \epsilon \\
 \rightarrow e^{-n} &< \frac{\epsilon}{4} \rightarrow -n < \ln \frac{\epsilon}{4}
 \end{aligned}$$

پس بدست می‌آوریم که:

$$\rightarrow n > -\ln \frac{\epsilon}{4} = \ln \frac{4}{\epsilon}$$

```

import random
from math import ceil

import numpy as np

def second_smallest_index(arr):
    import math
    first = second = math.inf
    i_first = i_second = 0

    for i in range(0, len(arr)):
        if arr[i] < first:
            second = first
            i_second = i_first
            first = arr[i]
            i_first = i
        elif arr[i] < second and arr[i] != first:
            second = arr[i]
            i_second = i
    return i_second

def cluster(n):
    p = 0.1
    q = 0.01
    a_array = [[0] * n for _ in range(n)]
    w_array = [[0] * n for _ in range(n)]
    real_clusters = np.random.choice([1, 1], size=(n,),
    p=[0.5, 0.5])

    for j in range(n):
        for i in range(n):
            if real_clusters[i] == real_clusters[j]:
                w = p
                a = random.choices([0, 1], weights=(1 - p, p))[0]
            else:
                w = q
                a = random.choices([0, 1], weights=(1 - q, q))[0]
            w_array[i][j] = w
            a_array[i][j] = a

```



```

A = np.matrix(a_array)
W = np.matrix(w_array)
discovered_clusters_a = discover_clusters(A, n)
discovered_clusters_w = discover_clusters(W, n)
a_errors = min(
    sum(discovered_clusters_a[i] != real_clusters[i]
        for i in range(n)),
    sum(discovered_clusters_a[i] == real_clusters[i]
        for i in range(n))
)
w_errors = min(
    sum(discovered_clusters_w[i] != real_clusters[i]
        for i in range(n)),
    sum(discovered_clusters_w[i] == real_clusters[i]
        for i in range(n))
)
print("A errors: ", a_errors)
print("W errors: ", w_errors)

```

```

def discover_clusters(ma, n):
    degree = np.zeros(len(ma))
    row_sum = ma.sum(axis=1)
    for j in range(n):
        degree[j] = row_sum[j, 0]
    D = np.diag(degree)
    L = D - ma
    w, v = np.linalg.eig(L)
    u2 = v[:, second_smallest_index(w)]
    discovered_clusters = [ceil(x.real) * 2 - 1 for x in u2]
    return discovered_clusters

```

```

n_values = [25, 50, 100, 200, 400, 800]
for n in n_values:
    print("n = ", n)
    cluster(n)

```

خلاصه‌ی تحقیق و گزارش رو این‌جا می‌نویسیم. یکی از منابع این تحقیق، همان فایل *Kmeans* داده شده هستش. در واقع این الگوریتم برای خوشه‌بندی داده‌هایی به کار می‌رود که به شکل پارتیشن‌بندی قرار ندارند. یعنی داده‌هایی که در یک خوشه نزدیک به هم هستند. سپس داده‌ها تبدیل می‌شوند و در فضایی n بعدی می‌روند و خوشه‌ها آن‌جا پارتیشن‌بندی می‌شوند. در این‌جا می‌توان با الگوریتمی مثل $k - means$ داده‌ها را به خوشه و پارتیشن‌های مختلف افراز کرد.

سوال ۳۶. سوال شبیه‌سازی ۱۴

```
import random
from math import ceil
from sklearn.datasets import fetch_california_housing
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np

def second_smallest_index(arr):
    import math
    first = second = math.inf
    i_first = i_second = 0

    for i in range(0, len(arr)):
        if arr[i] < first:
            second = first
            i_second = i_first
            first = arr[i]
            i_first = i
        elif arr[i] < second and arr[i] != first:
            second = arr[i]
            i_second = i
    return i_second

def cluster(n):
    p = 0.1
    q = 0.01
    a_array = [[0] * n for _ in range(n)]
    w_array = [[0] * n for _ in range(n)]
    real_clusters = np.random.choice([1, 1], size=(n,), p=[0.5, 0.5])
```

```

for j in range(n):
    for i in range(n):
        if real_clusters[i] == real_clusters[j]:
            w = p
            a = random.choices([0, 1], weights=(1 - p, p))[0]
        else:
            w = q
            a = random.choices([0, 1], weights=(1 - q, q))[0]
        w_array[i][j] = w
        a_array[i][j] = a

```

```

A = np.matrix(a_array)
W = np.matrix(w_array)
discovered_clusters_a = discover_clusters(A, n)
discovered_clusters_w = discover_clusters(W, n)
a_errors = min(
    sum(discovered_clusters_a[i] != real_clusters[i]
        for i in range(n)),
    sum(discovered_clusters_a[i] == real_clusters[i]
        for i in range(n))
)
w_errors = min(
    sum(discovered_clusters_w[i] != real_clusters[i]
        for i in range(n)),
    sum(discovered_clusters_w[i] == real_clusters[i]
        for i in range(n))
)
print("A errors: ", a_errors)
print("W errors: ", w_errors)

```

```

def discover_clusters(ma, n):
    degree = np.zeros(len(ma))
    row_sum = ma.sum(axis=1)
    for j in range(n):
        degree[j] = row_sum[j, 0]
    D = np.diag(degree)
    L = D - ma
    w, v = np.linalg.eig(L)
    u2 = v[:, second_smallest_index(w)]
    discovered_clusters = [ceil(x.real) * 2 - 1 for x in u2]
    return discovered_clusters

```

```

california_housing = fetch_california_housing(as_frame=True)
med_incs = np.array(california_housing.data[:, 'MedInc'])
.reshape(1, 1)
kmeans = KMeans(n_clusters=3, random_state=0, max_iter=1000,
n_init="auto").fit(med_incs)
labels = kmeans.labels_
colors = [label + 100 for label in labels]
df = pd.DataFrame(data=california_housing.data,
columns=california_housing.feature_names)
df.plot(kind='scatter', x='Latitude', y='Longitude',
color=colors, alpha=0.5)

```

سوال ۳۷. سوال شبیه‌سازی ۱۵

```

import matplotlib.pyplot as plt
import networkx as nx
import numpy as np
from sklearn.cluster import KMeans

def spectral_cluster(matrix, k):
    n = len(matrix)
    D = [[0] * n for i in range(n)]
    for i in range(len(matrix)):
        sum = 0
        for j in range(len(matrix[i])):
            sum += matrix[i][j]
        D[i][i] = sum

    L = [[0] * n for i in range(n)]
    for i in range(len(matrix)):
        for j in range(len(matrix[i])):
            L[i][j] = D[i][j] - matrix[i][j]

    u, v = np.linalg.eig(L)
    indices = np.argsort(u)[1:]
    V = []
    for i in range(k):
        V.append(v[:, indices[i]])

    return np.real(V)

```

```

G = nx.karate_club_graph()
n = len(G.nodes)

A = [[0 for i in range(n)] for j in range(n)]
for i in G.edges:
    A[i[0]][i[1]] = 1
    A[i[1]][i[0]] = 1

V = np.array(spectral_cluster(A, 2)).T

for k in range(2, 5):
    kmeans = KMeans(n_clusters=k, random_state=0, n_init="auto").fit(V)
    nx.draw(G, node_color=kmeans.labels_+1, with_labels=True)
    plt.show()

```

سوال ۳۸. سوال شبیه‌سازی ۱۶

```

import matplotlib.pyplot as plt
import numpy as np
import networkx as nx
from sklearn.cluster import KMeans

def spectral_cluster(matrix, k):
    n = len(matrix)
    D = [[0] * n for i in range(n)]
    for i in range(len(matrix)):
        sum = 0
        for j in range(len(matrix[i])):
            sum += matrix[i][j]
        D[i][i] = sum

    L = [[0] * n for i in range(n)]
    for i in range(len(matrix)):
        for j in range(len(matrix[i])):
            L[i][j] = D[i][j] - matrix[i][j]

    u, v = np.linalg.eig(L)
    indices = np.argsort(u)[1:]
    V = []
    for i in range(k):

```

```

        V.append(v[:, indices[i]])

    return np.real(V)

def conductivity(A, z, s):
    cs = 0
    ms = 0
    for i in range(len(A)):
        if z[i] == s:
            for j in range(len(A)):
                if A[i][j] == 1:
                    if z[j] == s:
                        ms += 1
                    else:
                        cs += 1
    return cs / (ms + cs)

def mean_conductivity(A, z):
    sum = 0
    counter = 0
    for i in range(np.min(z), np.max(z) + 1):
        sum += conductivity(A, z, i)
        counter += 1

    return sum / counter

if __name__ == "__main__":
    G = nx.karate_club_graph()
    n = len(G.nodes)

    A = [[0 for i in range(n)] for j in range(n)]
    for i in G.edges:
        A[i[0]][i[1]] = 1
        A[i[1]][i[0]] = 1

    V = np.array(spectral_cluster(A, 2)).T

    conductivities = []
    for k in range(2, 11):
        kmeans = KMeans(n_clusters=k, random_state=0, n_init="auto").fit(V)

```

```
conductivities.append(mean_conductivity(A, kmeans.labels_ + 1))
```

```
plt.plot(range(2, 11), conductivities)
plt.xlabel("clusters count")
plt.ylabel("mean conductivity")
plt.show()
```

سوال ۳۹. سوال تئوری ۲۳

هر جفت دوست به احتمال p درست تعیین شده و هر جفت غیردوست هم به احتمال $q = 1 - p$ درست تعیین میشود.

تعداد جفت‌های غیردوست

$$n * (n - 1) / 2 - m$$

است. پس طبق اصل ضرب داریم:

$$p^m (1 - p)^{\binom{n}{2} - m}$$

سوال ۴۰. سوال تئوری ۲۴

تعداد کل حالات برابر

$$\binom{\binom{n}{2}}{m}$$

و یکی از آنها را به احتمال برابر انتخاب می‌کنیم.

سوال ۴۱. سوال تئوری ۲۵

هر جفت مستقل از بقیه به احتمال p یال می‌کشیم و به احتمال

$$q = 1 - p$$

یال نمی‌کشیم. برای m تا از جفت‌ها در صورت یال کشیدن رابطه درست تعیین شده است. یعنی به احتمال p

برای $k = \binom{n}{2} - m$ جفت هم به احتمال q رابطه هم‌سلیفگی درست تعیین می‌شود.

X را تعداد یال‌هایی تعریف می‌کنیم که به درستی کشیده شده‌اند و Y را هم تعداد یال‌هایی تعریف می‌کنیم که به درستی کشیده نشده‌اند. هدف سوال $P(X + Y \geq \frac{m+k}{5})$ است.

می‌دانیم که:

$$X \sim \text{Binom}(m, p)$$

$$Y \sim \text{Binom}(k, q)$$

$$E[X] = mp \quad \text{Var}[x] = mpq$$

$$E[Y] = kq \quad \text{Var}[x] = kpq$$

جواب را می‌توان به صورت جمع یک سری نوشت ولی برای محاسبه رابطه مستقیم، با قضیه حد مرکزی X و Y را تخمین می‌زنیم.

$$X \approx \text{Normal}(mp, mpq)$$

$$Y \approx \text{Normal}(kq, kpq)$$

و جمع دو متغیر تصادفی که از توزیع نورمال پیروی می‌کنند، یک توزیع نورمال است.

$$X + Y \approx \text{Normal}(mp + kq, mpq + kpq = (m + k)pq)$$

$$Z = \frac{X+Y-mp-kq}{\sqrt{(m+k)pq}} \quad Z \approx \text{Normal}(0, 1)$$

$$P(X + Y \geq \frac{m+k}{\delta}) = P(Z \geq \frac{\frac{m+k}{\delta} - mp - kq}{\sqrt{(m+k)pq}}) = 1 - \phi\left(\frac{\frac{m+k}{\delta} - mp - kq}{\sqrt{(m+k)pq}}\right)$$

سوال ۴۲. سوال شبیه‌سازی ۱۷

```
from random import random

n=1000
p=0.0034
m=3000
N=10
def simul():
    edges=0
    for i in range(n):
        for j in range(i):
            if random()<p:
                edges+=1
    return edges

average=0
for i in range(N):
    average+=simul()
average/=N
print(average)
```

خیر. جواب به دست آمده حدوداً نصف m است.

سوال ۴۳. سوال تئوری ۲۶

طبق قانون اعداد بزرگ، این مقدار میانگین باید حدود امید ریاضی خروجی کد باشد.

$\binom{n}{2}$ جفت راس داریم و هر جفت به احتمال p و مستقل از بقیه یال دارند. پس از توزیع باینومیل پیروی میکنند و امید ریاضی تعداد یال‌ها برابر $p\binom{n}{2}$ است.

برای مقادیر پرسش شبیه‌سازی جواب برابر $۱۶۹۸/۳$ است.

به طور کلی هم باید رابطه $|p - \frac{m}{\binom{n}{2}}| < \epsilon$ برقرار باشد که مقدار اپسیلون به دقت مورد نظر بستگی دارد.

سوال ۴۴. سوال شبیه‌سازی ۱۸

```
from random import random
import matplotlib.pyplot as plt

n=1000
p=0.00016
N=10

def simul():
    deg=[0]*n
    for i in range(n):
        for j in range(i):
            if random()<p:
                deg[i]+=1
                deg[j]+=1

    L=sum(deg)/n
    res=0
    for i in range(n):
        if (deg[i]>=L):
            res+=1

    return res

results=[simul() for i in range(N)]
average=sum(results)/N
print(average)

deg=[0]*n
for i in range(n):
    for j in range(i):
        if random()<p:
            deg[i]+=1
            deg[j]+=1

plt.hist(deg)
```

```
plt.show()
```

Output : ۱۵۱/۳

سوال ۴۵. سوال تئوری ۲۷

$$(n-1)p = 999 \times 0.00016 = 0.15984$$

سوال ۴۶. سوال تئوری ۲۸

با توجه به پرسش قبل و بزرگ بودن n طبق قضیه حد مرکزی میتوانیم متغیر تصادفی deg_i که درجه راس i است را با توزیع نورمال تخمین بزنیم.

$$Var[deg_i] = (n-1)p(1-p) \simeq 0.16$$

پس می‌توانیم فرض کنیم احتمال اینکه راس درجه بیشتر از ۲ داشته باشیم صفر است. و اینکه احتمال اینکه میانگین درجات زیاد باشد نیز نزدیک صفر است، پس از آن هم صرف نظر می‌کنیم. در نتیجه احتمال اینکه یک نفر هم‌رنگ نباشد برابر احتمال این است که این راس هیچ یالی نداشته باشد. و این مقدار برابر $(1-p)^{n-1}$ است. در نتیجه احتمال هم‌رنگ بودن یک نفر برابر $1 - (1-p)^{n-1} \simeq 0.147$ است و امیدریاضی تعداد هم‌رنگ‌ها برابر ۱۴۷ می‌شود.

سوال ۴۷. سوال شبیه‌سازی ۱۹

```
from random import random

n=3000
p=0.01
N=5

def simul():
    G=[[0]*n for i in range(n)]
    for i in range(n):
        for j in range(i):
            if random()<p:
                G[i][j]=G[j][i]=1

    res1=0
    res2=0
    for v in range(n):
```

```

adj=[]
for u in range(v):
    if G[u][v]:
        adj.append(u)

res=0
for u in adj:
    for w in adj:
        if u<w:
            if G[u][w]:
                res1+=1
            else:
                res2+=1

return res1, res2

mean1=0
mean2=0
for i in range(N):
    res1, res2 = simul()
    mean1+=res1
    mean2+=res2
mean1/=N
mean2/=N
print(mean1)
print(mean2)

```

Output :

۴۵۰۳/۸

۴۴۷۶۹۱/۲

سوال ۴۸. سوال تئوری ۲۹

خاصیت تراگذری = مثلث به دلیل خطی بودن امیدریاضی، احتمال وجود خاصیت را برای ۳ راس حساب کرده و در $\binom{n}{3}$ ضرب می‌کنیم
تراگذری:

$$\binom{n}{3} p^3$$

زنجیره‌ای:

$$\binom{n}{3} 3p^2(1-p)$$

$$\begin{aligned}
 P(r \text{ edges} \mid \text{at least } r \text{ edges}) &= \\
 \frac{P(r \text{ edges})}{P(\text{at least } r \text{ edges})} &= \\
 \frac{p^r}{p^r + r p^r (1-p)} &= \\
 \frac{p}{p + r(1-p)} &= \\
 \frac{p}{r - rp} = 0.003
 \end{aligned}$$

```

from random import random

n=1000
p=0.003

G=[[0]*n for i in range(n)]
for i in range(n):
    for j in range(i):
        if random()<p:
            G[i][j]=G[j][i]=1

mean=0
for v in range(n):
    adj=[]
    for u in range(v):
        if G[u][v]:
            adj.append(u)

    res=0
    for u in adj:
        for w in adj:
            if u<w and G[u][w]:
                res+=1

    mean+=res

mean/=n
print(mean)

```

سوال ۵۱. سوال تئوری ۳۱

امید ریاضی تعداد مثلث‌های حاوی یک رأس خاص را می‌خواهیم. پس به $\binom{n-1}{2}$ حالت ۲ رأس انتخاب کرده و به احتمال p^3 یک مثلث می‌سازند. چون امید ریاضی خطی است جواب برابر با $\binom{n-1}{2}p^3$ می‌شود.

سوال ۵۲. سوال شبیه‌سازی ۲۱

```
from random import random
import networkx as ntx

N=1
n=1000
p=0.033
# in problem statement p=0.0033,
# but the problem author is an idiot
# who does not know basic graph theory and probability
# if p=0.0033, its easy to prove the probability of
# having a connected graph is almost 0
# **** EE project

def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)
    return G

def simul():
    G=gen_graph(n, p)
    sp = dict(ntx.all_pairs_shortest_path_length(G))
    mean=0
    for i in range(n):
        for j in range(i):
            mean+=sp[i][j]
    return mean/(n*(n-1)/2)
```

```

results=[simul() for i in range(N)]
average=sum(results)/N
print(average)

```

Output : ۲/۲۹۵۴۶۱۴۶۱۴۶۱۴۶۱۵

سوال ۵۳. سوال شبیه سازی ۲۲

```

from random import random
import networkx as ntx

N=100
n=50
p=0.34

def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)

    return G

def simul():
    G=gen_graph(n, p)
    return ntx.diameter(G)

results=[simul() for i in range(N)]
average=sum(results)/N
print(average)

```

Output : ۲/۸۲

سوال ۵۴. سوال شبیه سازی ۲۳

```

from random import random
import networkx as ntx
import matplotlib.pyplot as plt

```

```

p=0.34
N=100

def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)
    return G

def simul(n):
    G=gen_graph(n, p)
    if ntx.connected.is_connected(G):
        return ntx.diameter(G)
    return None

def mean_simul(n):
    results=[]
    for i in range(N):
        res=simul(n)
        if res!=None:
            results.append(res)

    return sum(results)/len(results)

x=range(10, 201, 10)
y=[mean_simul(n) for n in x]

plt.plot(x, y, color='red')
plt.show()

```

این نمودار نزولی است و با افزایش تعداد راس‌ها به سمت ۲ میل می‌کند.
 اگر قطر یک گراف ۲ باشد بدین معنی اسد که هر دو راس غیرهمسایه، یک همسایه مشترک دارند.

سوال ۵۵. سوال تئوری ۳۲

$E_{u,v}$ را برابر یال داشتن دو راس تعریف می‌کنیم.

$$P(I_{u,v}) = \prod_{w \neq u,v} (1 - P(I_{u,w})P(I_{u,w}))$$

$$P(I_{u,v}) = \prod_{w \neq u,v} (1 - p^r)$$

$$P(I_{u,v}) = (1 - p^r)^{n-r}$$

سوال ۵۶. سوال تئوری ۳۳

امیدریاضی خطی است پس امیدریاضی تعداد جفت‌های بدون همسایه مشترک برابر جمع احتمال همسایه مشترک نداشتن تمام جفت راس‌ها است. و این احتمال در پرسش قبلی محاسبه شده، پس جواب برابر است با:

$$\binom{n}{r} (1 - p^r)^{n-r}$$

سوال ۵۷. سوال تئوری ۳۴

Markov Inequality :

$$P(X_n \geq 1) \leq \frac{E[X_n]}{1} = \binom{n}{r} (1 - p^r)^{n-r}$$

$$\lim_{n \rightarrow \infty} \binom{n}{r} (1 - p^r)^{n-r} =$$

$$\lim_{n \rightarrow \infty} \frac{n(n-1)}{r(1-p^r)^{r-n}} =$$

$$\lim_{n \rightarrow \infty} \frac{n(n-1)}{r(e^{\ln(1-p^r)})^{r-n}} =$$

$$\lim_{n \rightarrow \infty} \frac{n(n-1)}{r e^{\ln(1-p^r)(r-n)}} =$$

$$\lim_{n \rightarrow \infty} \frac{rn - 1}{-r \ln(1-p^r) e^{\ln(1-p^r)(r-n)}} =$$

$$\lim_{n \rightarrow \infty} \frac{r}{-r \ln(1-p^r)^r e^{\ln(1-p^r)(r-n)}} =$$

$$\frac{-1}{\ln(1-p^r)^r} \lim_{n \rightarrow \infty} e^{\ln(1-p^r)(n-r)} =$$

$$\frac{-1}{\ln(1-p^r)^r} \lim_{n \rightarrow \infty} (1-p^r)^{n-r} = \bullet$$

سوال ۵۸. سوال تئوری ۳۵

طبق پرسش قبل احتمال اینکه حداقل یک جفت راس همسایه مشترک نداشته باشند، با زیاد شدن n به سمت صفر میل می‌کند. در نتیجه برای n های بزرگ به احتمال تفریبی یک هر دو راسی همسایه مشترک دارند و در نتیجه فاصله آنجا حداکثر ۲ است. همچنین احتمال ۱ بودن قطر گراف هم با زیاد شدن n به سمت صفر میل می‌کند چون این احتمال برابر

$$p^{\binom{n}{2}}$$

است و

$$\lim_{n \rightarrow \infty} p^{\binom{n}{2}} = 0$$

پس با زیاد شدن n به احتمال تقریباً ۱ قطر گراف ۲ است. و این عدد به p وابسته نیست. تنها کافی است که مقدار p برابر صفر یا یک نباشد. این نتیجه با نتیجه شبیه‌سازی نیز تطابق دارد. در آنجا هم قطر گراف به ۲ میل می‌کند

سوال ۵۹. سوال شبیه‌سازی ۲۴

```
from random import random
import networkx as ntx

n=100
p=0.34
N=100

def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)
    return G

def simul(n):
    G=gen_graph(n, p)
    return sum(list(ntx.triangles(G).values()))/3

def mean_simul(n):
    results=[]
    for i in range(N):
        res=simul(n)
        if res!=None:
```

```
results.append(res)
```

```
return sum(results)/len(results)
```

```
print(mean_simul(n))
```

Output : ۶۳۲۳/۸۴

سوال ۶۰. سوال شبیه سازی ۲۵

```
from random import random
import networkx as ntx
import matplotlib.pyplot as plt
```

```
N=100
```

```
def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)

    return G
```

```
def simul(n):
    G=gen_graph(n, 60/n**2)
    return sum(list(ntx.triangles(G).values()))//3
```

```
def mean_simul(n):
    results=[]
    for i in range(N):
        res=simul(n)
        if res!=None:
            results.append(res)

    return sum(results)/len(results)
```

```
x=range(10, 101, 10)
y=[mean_simul(n) for n in x]
```

```
plt.plot(x, y, color='red')
plt.show()
```

سوال ۶۱. سوال شبیه سازی ۲۶

خیر. این مقدار به عدد خاصی میل نمی کند و با افزایش تعداد راس ها زیاد می شود.

```
from random import random
import networkx as ntx
import matplotlib.pyplot as plt

p=0.34
N=100

def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)
    return G

def simul(n):
    G=gen_graph(n, p)
    return sum(list(ntx.triangles(G).values()))//3

def mean_simul(n):
    results=[]
    for i in range(N):
        res=simul(n)
        if res!=None:
            results.append(res)

    return sum(results)/len(results)

x=range(10, 101, 10)
y=[mean_simul(n) for n in x]

plt.plot(x, y, color='red')
plt.show()
```

```
from random import random
import networkx as ntx
import matplotlib.pyplot as plt

N=100

def gen_graph(n, p) > ntx.Graph:
    G=ntx.empty_graph(n)
    for i in range(n):
        for j in range(i):
            if random()<p:
                G.add_edge(i, j)

    return G

def simul(n):
    G=gen_graph(n, 1/n)
    return sum(list(ntx.triangles(G).values()))//3

def mean_simul(n):
    results=[]
    for i in range(N):
        res=simul(n)
        if res!=None:
            results.append(res)

    return sum(results)/len(results)

x=range(50, 1201, 50)
y=[mean_simul(n) for n in x]

plt.plot(x, y, color='red')
plt.show()
```

این مقدار با وجود زیاد شدن تعداد راس‌ها باز هم در بازه $0/1$ تا $0/2$ قرار دارد. پس می‌توان نتیجه گرفت با زیاد شدن تعداد راس‌ها به عددی در این بازه مایل می‌شود

$$P_{i,j} = \begin{cases} \frac{1}{d(i)} & A_{i,j} = 1 \\ 0 & A_{i,j} = 0 \end{cases}$$

سوال ۶۴. سوال تئوری ۳۷

$\frac{1}{d(i)}$ قرار دارد.

$$\implies P = AD^{-1}$$

سوال ۶۵. سوال تئوری ۳۸

$$\sum_{x=1}^n P_{ix} \cdot P_{xj}$$

که می‌توان آن را به شکل مسیرهای به طول دو از i به j تعریف کرد.

سوال ۶۶. سوال تئوری ۳۹

$$P_{i,j}^{(t)} = [\mathbf{P}^t]_{i,j}$$

سوال ۶۷. سوال تئوری ۴۰

مسیر $j \rightarrow x_1 \rightarrow \dots \rightarrow x_{t-1} \rightarrow i$ را در نظر بگیرید. احتمال اینکه با شروع از i این مسیر طی شود برابر:

$$A_1 = \frac{1}{d(x_1)} \cdot \dots \cdot \frac{1}{d(x_{t-1})} \cdot \frac{1}{d(j)}$$

همچنین احتمال اینکه برعکس این مسیر با شروع از j طی شود برابر:

$$A_2 = \frac{1}{d(x_{t-1})} \cdot \dots \cdot \frac{1}{d(x_1)} \cdot \frac{1}{d(i)}$$

اگر نسبت دو مسیر A_1 و A_2 را بگیریم، می‌فهمیم:

$$\frac{A_1}{A_2} = \frac{d(i)}{d(j)}$$

و این به ازای هر مسیر از i به j برقرار است.

$$\Rightarrow \frac{P_{i,j}^{(t)}}{P_{j,i}^{(t)}} = \frac{d(i)}{d(j)}$$

سوال ۶۸. سوال تئوری ۴۱

اگر این دو کاربر i و j با هم هم‌سلیقه باشند، احتمال اینکه در یک خوشه قرار بگیرند بیشتر است که در نتیجه‌ی آن، $P_{ij}^{(t)}$ افزایش می‌یابد. در این صورت، اگر k اگر i و j هم‌خوشه باشند، با احتمال زیادی با آنها هم‌خوشه است که باعث می‌شود احتمال $P_{ik}^{(t)}$ و $P_{jk}^{(t)}$ بالا رود.

سوال ۶۹. سوال تئوری ۴۲

برای بدست آوردن احتمال رفتن از یک خوشه C به راسی مثل k ، میانگین احتمال رئوس آن خوشه را در نظر می‌گیریم (البته احتمالها برای اعضای یک خوشه بسیار مشابه است):

$$P_{C,k}^{(t)} = \frac{\sum_{i=1}^{\text{size of } C} P_{i,k}^{(t)}}{\text{size of } C}$$

واضحاً به طور برعکس $P_{k,C}^{(t)}$ پس خواهیم داشت:

$$r_{C_1, C_2} = \sqrt{\sum_{k=1}^n \frac{(P_{C_1,k}^{(t)} - (P_{k,C_2}^{(t)})^2}{d(k)}}$$

سوال ۷۰. سوال تئوری ۴۳

تعداد یال‌های درون و بیرون خوشه‌ها رو می‌شه معیاری برای یافتن خوشه‌بندی بهینه در نظر بگیریم و مثلاً زمانی که تعداد یال‌های درون اون‌ها از بیرون اون‌ها بیشتر باشه، معیار خوبی می‌دونیم. در واقع برتری تعداد یال‌های درون به بیرون خوشه‌ها رو می‌شه معیاری در نظر گرفت.

سوال ۷۱. سوال شبیه‌سازی ۲۸

```
import math
import numpy as np
import matplotlib.pyplot as plt
import networkx as nx

def P_t(t, A, D):
    P = np.dot(np.linalg.inv(D), A)

    result = P
```

```

    for i in range(t - 1):
        result = np.dot(result, P)
    return result

```

```

def R_i_j(n, t, A, D, d, i, j):
    result = 0
    P = P_t(t, A, D)
    for k in range(n):
        result += ((P[i][k] - P[j][k]) ** 2) / d[k]
    return math.sqrt(result)

```

```

def P_Ci(P, ci, A, k):
    result = 0
    for i in ci:
        result += P[i][k]

    return result / len(ci)

```

```

def RC_iC_j(n, t, A, D, d, C1, C2):
    P = P_t(t, A, D)
    result = 0
    for k in range(n):
        result += ((P_Ci(P, C1, A, k) - P_Ci(P, C2, A, k)) ** 2) / d[k]
    return math.sqrt(result)

```

```

G = nx.karate_club_graph()
n = len(G.nodes)
t = 2

```

```

A = [[0 for i in range(n)] for j in range(n)]

```

```

edgesTotal = 0
for i in G.edges:
    edgesTotal += 1
    A[i[0]][i[1]] = 1
    A[i[1]][i[0]] = 1

```

```

D = [[0 for i in range(n)] for j in range(n)]

```

```

d = []
for i in range(n):
    s = sum(A[i])
    d.append(s)
    D[i][i] = s

C = []
for i in range(n):
    c = []
    c.append(i)
    C.append(c)

diffs = []

edgesIn = []
edgesOut = []

while len(C) > 1:
    first = 0
    second = 0
    minOfDif = 1e7
    for i in range(len(C)):
        for j in range(i):
            r = RC_iC_j(n, t, A, D, d, C[i], C[j])
            if minOfDif > r:
                minOfDif = r
                first = i
                second = j

    edIn = 0
    edOut = 0
    for i in range(len(C)):
        for j in range(len(C[i])):
            for z in range(j):
                if A[j][z] == 1:
                    edIn += 1

    edOut = edgesTotal - edIn

    edgesIn.append(edIn)
    edgesOut.append(edOut)

```



```

cfirst = C.pop(first)
csecond = C.pop(second)
C.append(cfirst + csecond)

```

```

r = 0
for i in range(len(C)):
    for j in range(i):
        r += RC_iC_j(n, t, A, D, d, C[i], C[j])

```

```

diffs.append(r)

```

```

if 2 * edOut <= edIn:
    color_map = []
    for node in G:
        counter = 0
        for i in range(len(C)):
            if counter == 0:
                for j in C[i]:
                    if j == node and counter == 0:
                        color_map.append(i)
        nx.draw(G, node_color=color_map, with_labels=True)
    plt.show()
    plt.clf()
    break

```

```

edIn = 0
edOut = 0
for i in range(len(C)):
    for j in range(len(C[i])):
        for z in range(j):
            if A[j][z] == 1:
                edIn += 1

```

```

edOut = edgesTotal - edIn

```

```

edgesIn.append(edIn)
edgesOut.append(edOut)

```

```

print(edgesIn)
print(edgesOut)

```

```

import math
import numpy as np
import matplotlib.pyplot as plt
import networkx as nx

def P_t(t, A, D):
    P = np.dot(np.linalg.inv(D), A)

    result = P
    for i in range(t - 1):
        result = np.dot(result, P)
    return result

def R_i_j(n, t, A, D, d, i, j):
    result = 0
    P = P_t(t, A, D)
    for k in range(n):
        result += ((P[i][k] - P[j][k]) ** 2) / d[k]
    return math.sqrt(result)

def P_Ci(P, ci, A, k):
    result = 0
    for i in ci:
        result += P[i][k]

    return result / len(ci)

def RC_iC_j(n, t, A, D, d, C1, C2):
    P = P_t(t, A, D)
    result = 0
    for k in range(n):
        result += ((P_Ci(P, C1, A, k) - P_Ci(P, C2, A, k)) ** 2) / d[k]
    return math.sqrt(result)

G = nx.karate_club_graph()
n = len(G.nodes)

```

```

t = 5

A = [[0 for i in range(n)] for j in range(n)]

edgesTotal = 0
for i in G.edges:
    edgesTotal += 1
    A[i[0]][i[1]] = 1
    A[i[1]][i[0]] = 1

D = [[0 for i in range(n)] for j in range(n)]
d = []
for i in range(n):
    s = sum(A[i])
    d.append(s)
    D[i][i] = s

C = []
for i in range(n):
    c = []
    c.append(i)
    C.append(c)

diffs = []

edgesIn = []
edgesOut = []

while len(C) > 1:
    first = 0
    second = 0
    minOfDif = 1e7
    for i in range(len(C)):
        for j in range(i):
            r = RC_iC_j(n, t, A, D, d, C[i], C[j])
            if minOfDif > r:
                minOfDif = r
                first = i
                second = j

    edIn = 0
    edOut = 0

```

```

for i in range(len(C)):
    for j in range(len(C[i])):
        for z in range(j):
            if A[j][z] == 1:
                edIn += 1

edOut = edgesTotal - edIn

edgesIn.append(edIn)
edgesOut.append(edOut)

cfirst = C.pop(first)
csecond = C.pop(second)
C.append(cfirst + csecond)

r = 0
for i in range(len(C)):
    for j in range(i):
        r += RC_iC_j(n, t, A, D, d, C[i], C[j])

diffs.append(r)

if 2 * edOut <= edIn:
    color_map = []
    for node in G:
        counter = 0
        for i in range(len(C)):
            if counter == 0:
                for j in C[i]:
                    if j == node and counter == 0:
                        color_map.append(i)
        nx.draw(G, node_color=color_map, with_labels=True)
        plt.show()
        plt.clf()
    break

edIn = 0
edOut = 0
for i in range(len(C)):
    for j in range(len(C[i])):
        for z in range(j):
            if A[j][z] == 1:

```

```
        edIn += 1

edOut = edgesTotal - edIn

edgesIn.append(edIn)
edgesOut.append(edOut)

print(edgesIn)
print(edgesOut)
```

موفق باشید.